

2020 자율주행 교육

WeGo 위고 주식회사

1. 활성화 함수 계층 구현
2. 오차역전파 검증
3. 학습 관련 기술

01



활성화 함수 계층 구현

01. 활성화 함수 계층 구현

- ReLU 계층 구현(Class 로 구현)

$$y = \begin{cases} x, & x < 0 \\ 0, & x \geq 0 \end{cases}$$

$$\frac{\partial y}{\partial x} = \begin{cases} 1, & x < 0 \\ 0, & x \geq 0 \end{cases}$$



01. 활성화 함수 계층 구현

- ReLU 계층 구현(Class 로 구현)

```
class Relu:
    def __init__(self):
        self.mask = None

    def forward(self, x):
        self.mask = (x <= 0)
        out = x.copy()
        out[self.mask] = 0

        return out

    def backward(self, dout):
        dout[self.mask] = 0
        dx = dout

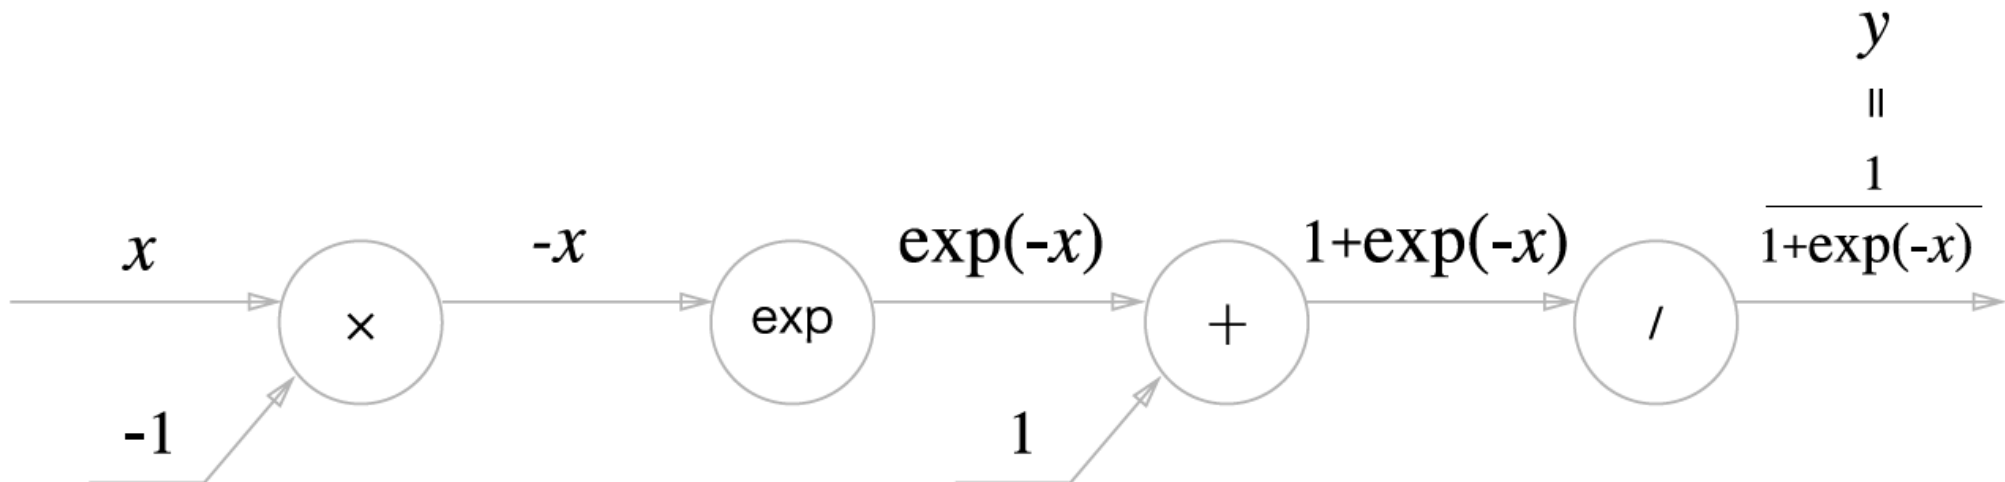
        return dx
```

Mask의 경우, 입력에 따라,
True 및 False를 가지는 값을 출력
이 후, out[self.mask]를 통해
True인 부분만 0으로 처리

01. 활성화 함수 계층 구현

- Sigmoid 계층 구현(Class 로 구현)

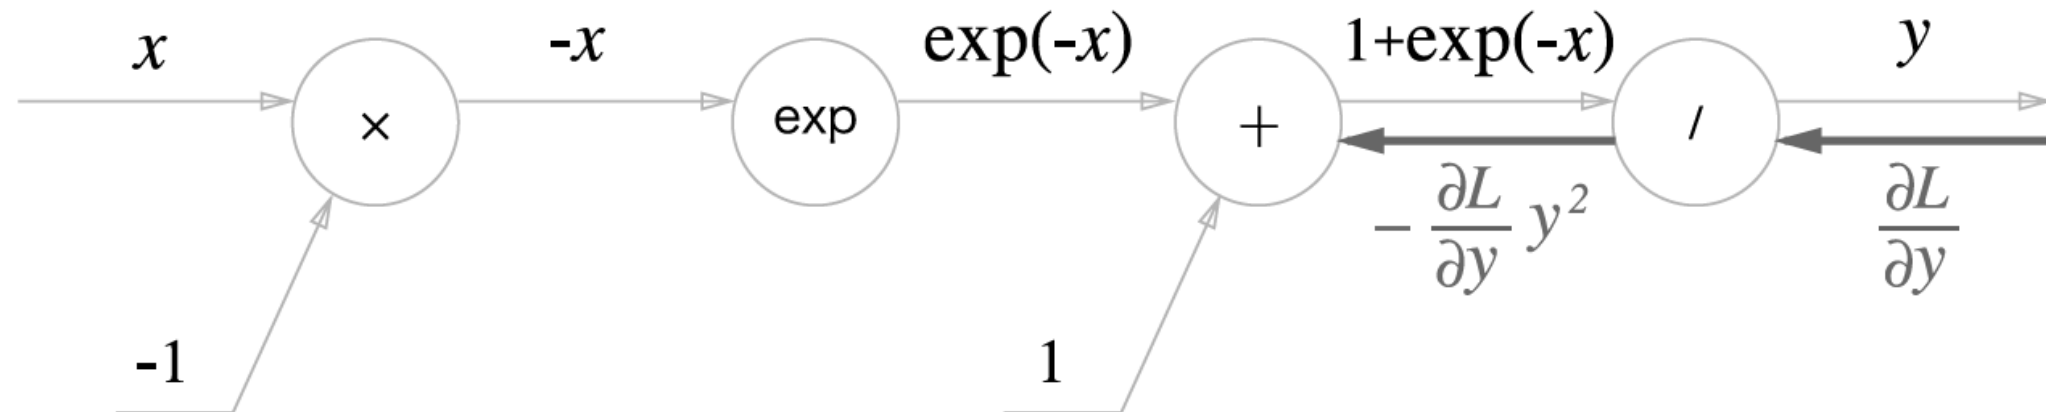
$$y = \frac{1}{1 + \exp(-x)}$$



01. 활성화 함수 계층 구현

- Sigmoid 계층 구현(Class 로 구현)

$$y = \frac{1}{x}, \frac{\partial y}{\partial x} = -\frac{1}{x^2} = -y^2$$

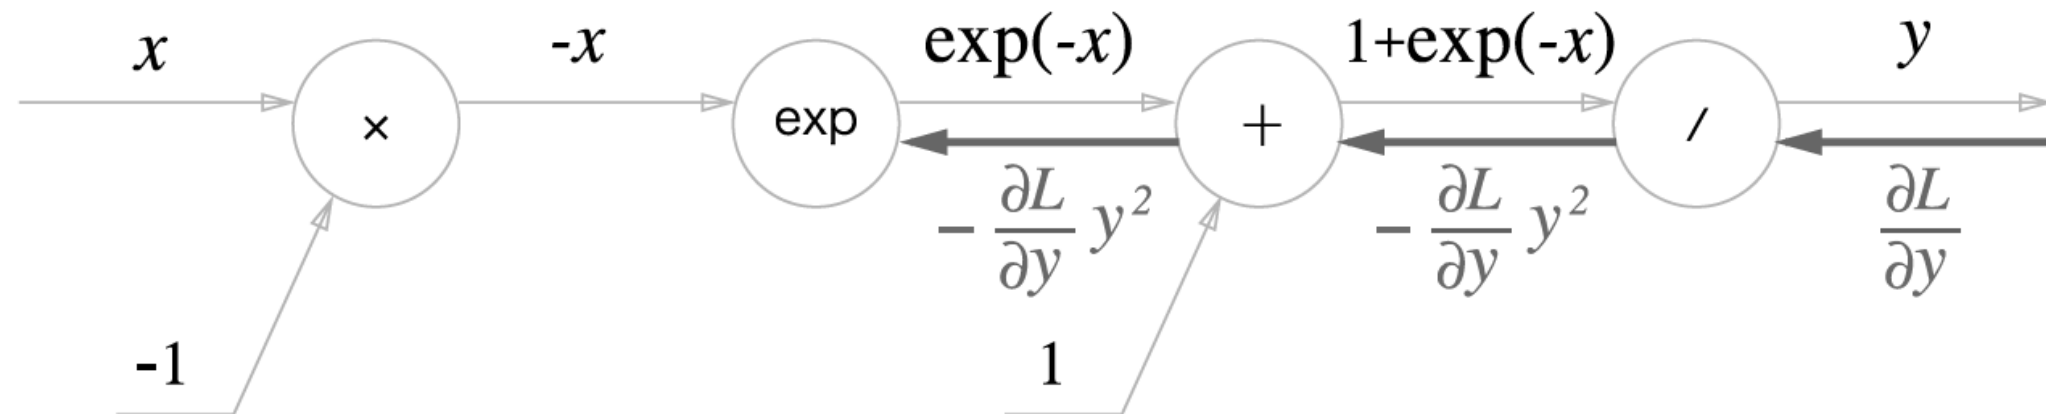


01. 활성화 함수 계층 구현

- Sigmoid 계층 구현(Class 로 구현)

$$y = \frac{1}{x}, \frac{\partial y}{\partial x} = -\frac{1}{x^2} = -y^2$$

덧셈 노드는 그대로 전달



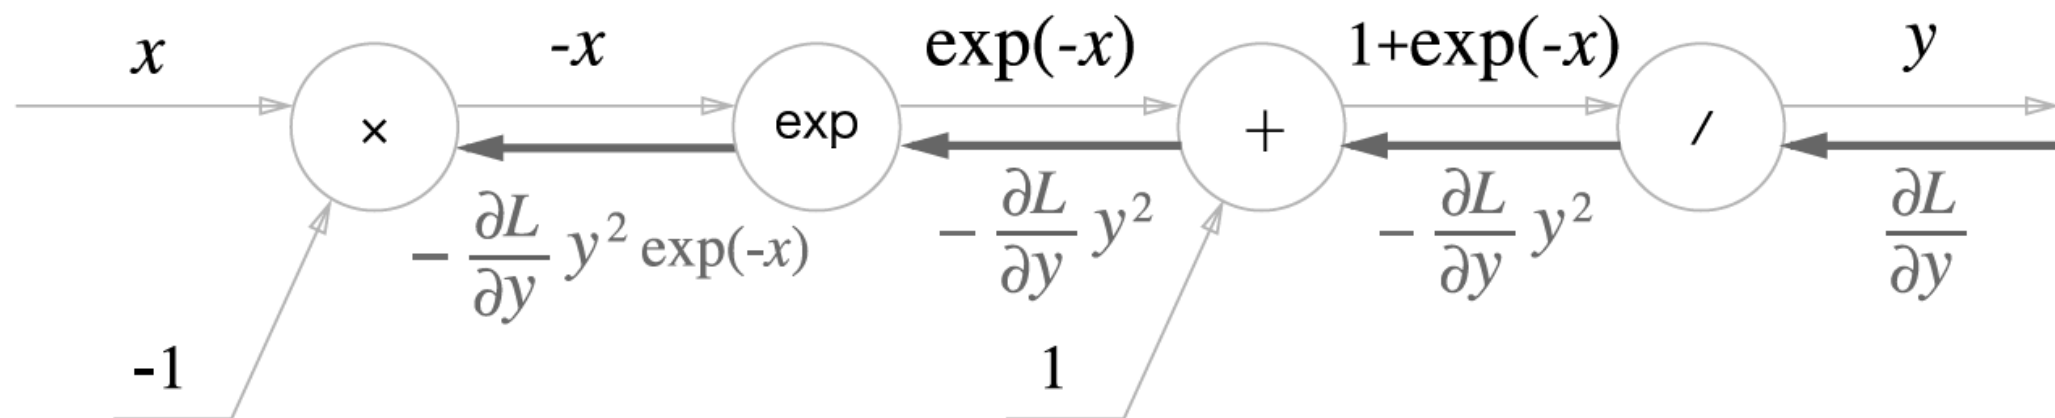
01. 활성화 함수 계층 구현

- Sigmoid 계층 구현(Class 로 구현)

$$\frac{\partial y}{\partial x} = \exp(x)$$

$$y = \frac{1}{x}, \frac{\partial y}{\partial x} = -\frac{1}{x^2} = -y^2$$

덧셈 노드는 그대로 전달



01. 활성화 함수 계층 구현

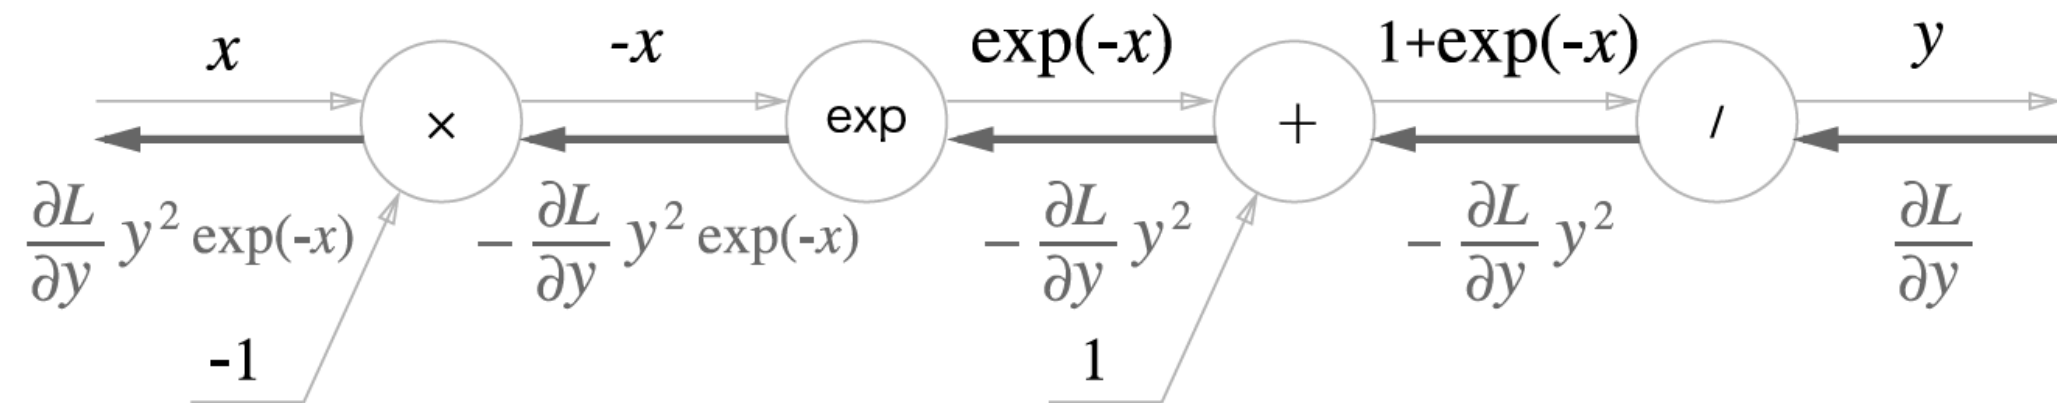
- Sigmoid 계층 구현(Class 로 구현)

$$\frac{\partial y}{\partial x} = \exp(x)$$

$$y = \frac{1}{x}, \frac{\partial y}{\partial x} = -\frac{1}{x^2} = -y^2$$


반대쪽에 해당하는 -1을 곱셈

덧셈 노드는 그대로 전달



01. 활성화 함수 계층 구현


- Sigmoid 계층 구현(Class 로 구현)



01. 활성화 함수 계층 구현

- Sigmoid 계층 구현(Class 로 구현)

$$\begin{aligned}\frac{\partial L}{\partial y} y^2 \exp(-x) &= \frac{\partial L}{\partial y} \frac{1}{(1 + \exp(-x))^2} \exp(-x) \\ &= \frac{\partial L}{\partial y} \frac{1}{(1 + \exp(-x))} \frac{\exp(-x)}{(1 + \exp(-x))} = \frac{\partial L}{\partial y} y(1 - y)\end{aligned}$$



01. 활성화 함수 계층 구현

- Sigmoid 계층 구현(Class 로 구현)

```
class Sigmoid:
    def __init__(self):
        self.out = None

    def forward(self, x):
        out = sigmoid(x)
        self.out = out

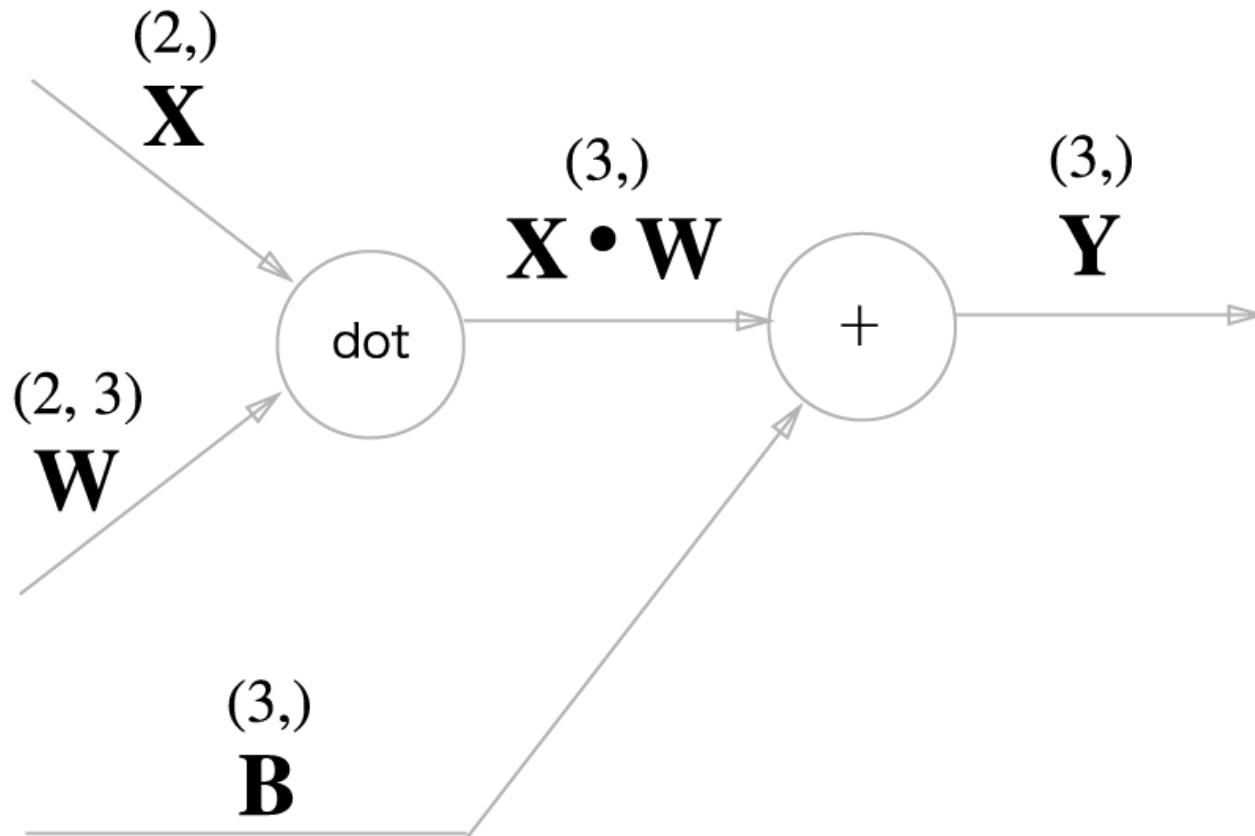
        return out

    def backward(self, dout):
        dx = dout * (1.0 - self.out) * self.out

        return dx
```

01. 활성화 함수 계층 구현

- Affine 계층 구현(Class 로 구현)
- 행렬의 곱을 기하학에서 Affine transformation이라 하여, Affine 계층이라고 함



01. 활성화 함수 계층 구현


- Affine 계층 구현(Class 로 구현)

$$\boxed{1} \quad \frac{\partial L}{\partial \mathbf{X}} = \frac{\partial L}{\partial \mathbf{Y}} \mathbf{W}^T$$

(2,) (3,) (3, 2)

$$\boxed{2} \quad \frac{\partial L}{\partial \mathbf{W}} = \mathbf{X}^T \frac{\partial L}{\partial \mathbf{Y}}$$

(2, 3) (2, 1) (1, 3)



01. 활성화 함수 계층 구현

- Batch용 Affine 계층 구현(Class 로 구현)

$$\boxed{1} \quad \frac{\partial L}{\partial \mathbf{X}} = \frac{\partial L}{\partial \mathbf{Y}} \cdot \mathbf{W}^T$$


(N, 2) (N, 3) (3, 2)

$$\boxed{2} \quad \frac{\partial L}{\partial \mathbf{W}} = \mathbf{X}^T \cdot \frac{\partial L}{\partial \mathbf{Y}}$$

(2, 3) (2, N) (N, 3)

$$\boxed{3} \quad \frac{\partial L}{\partial \mathbf{B}} = \frac{\partial L}{\partial \mathbf{Y}} \text{의 첫 번째 축(0축, 열방향)의 합}$$

(3) (N, 3)



01. 활성화 함수 계층 구현

- Batch용 Affine 계층 구현(Class 로 구현)

```
class Affine:
```

```
    def __init__(self, W, b):
```

```
        self.W = W
```

```
        self.b = b
```

```
        self.x = None
```

```
        self.dW = None
```

```
        self.db = None
```

```
    def forward(self, x):
```

```
        self.x = x
```

```
        out = np.dot(x, self.W) + self.b
```

```
        return out
```

```
    def backward(self, dout):
```

```
        dx = np.dot(dout, self.W.T)
```


```
        self.dW = np.dot(self.x.T, dout)
```

```
        self.db = np.sum(dout, axis=0)
```

```
        return dx
```

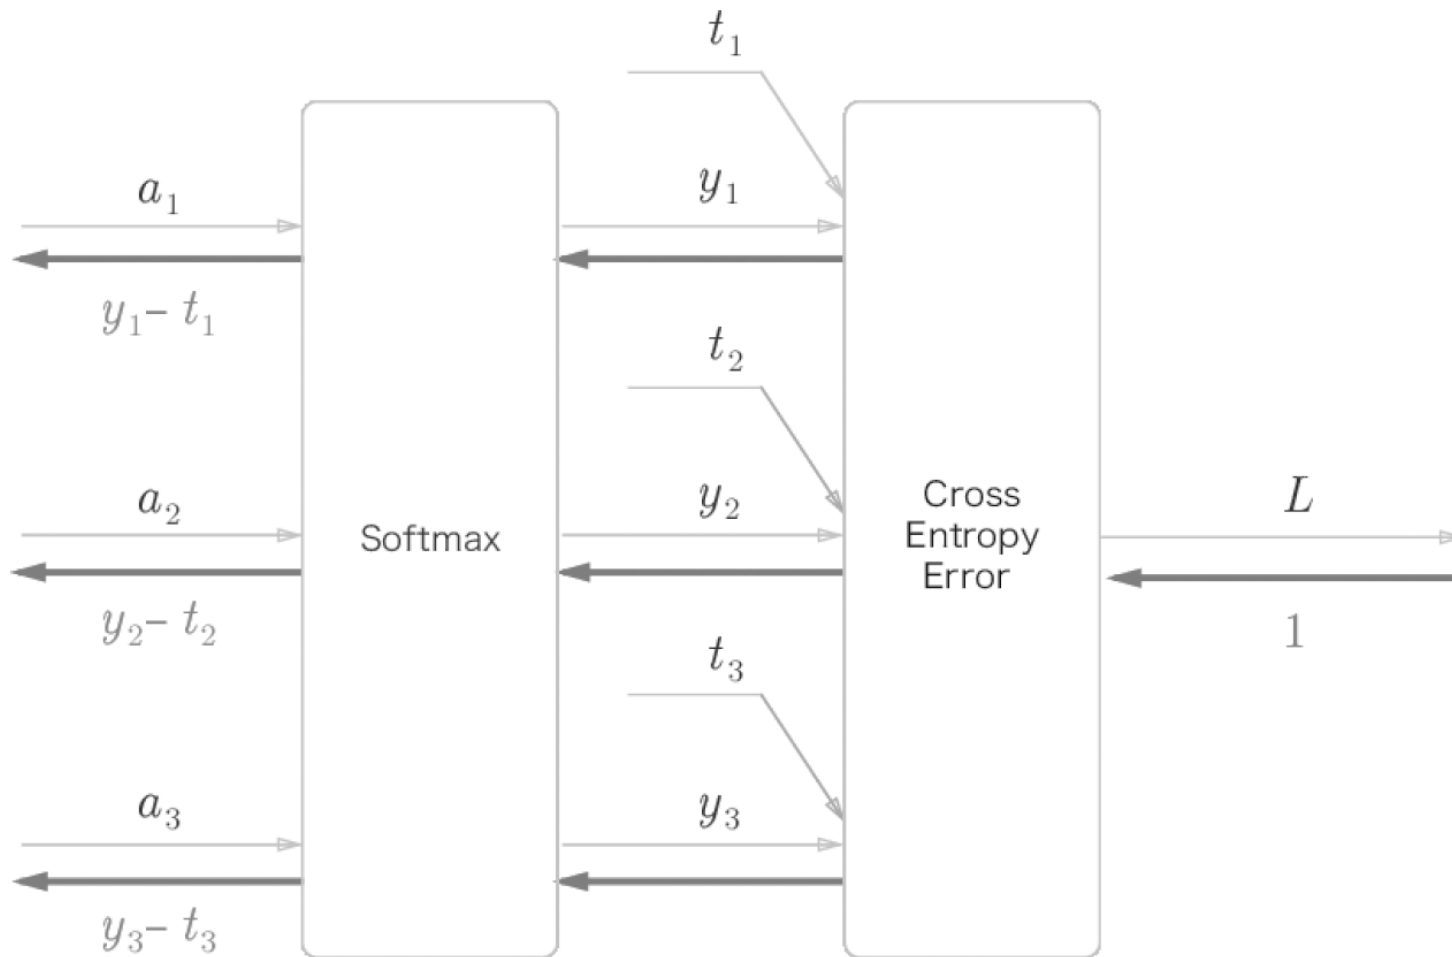
01. 활성화 함수 계층 구현

- Softmax-with-Loss 계층



01. 활성화 함수 계층 구현

- Softmax-with-Loss 계층



01. 활성화 함수 계층 구현

- Softmax-with-Loss 계층

```
class SoftmaxWithLoss:
    def __init__(self):
        self.loss = None
        self.y = None
        self.t = None

    def forward(self, x, t):
        self.t = t
        self.y = softmax(x)
        self.loss = cross_entropy_error(self.y, self.t)
        return self.loss

    def backward(self, dout=1):
        batch_size = self.t.shape[0]
        dx = (self.y - self.t) / batch_size
        return dx
```

02

오차역전파 검증

02. 오차역전파 검증

- 수치 미분을 이용한 방법과 오차역전파로 계산한 방법과의 비교
- 수치 미분의 경우 느리지만, 구현이 쉬워서 실수하기가 어려움
- 반면 오차역전파법은 빠르지만, 구현이 어려워서 실수가 많이 생길 위험이 있음
- 두 가지 방법의 비교를 통해 구현이 제대로 이루어졌는지 확인이 가능

02. 오차역전파 검증

- 수치 미분을 이용한 방법과 오차역전파로 계산한 방법과의 비교
- 둘 사이의 차이가 0이 되는 일은 잘 없음(계산의 정밀도의 한계가 존재)
- 거의 0에 가까운 값이 나오면 정상적인 구현

```
(x_train, t_train), (x_test, t_test) = load_mnist(normalize=True, one_hot_label=True)
```

```
network = TwoLayerNet(input_size=784, hidden_size=50, output_size=10)
```

```
x_batch = x_train[:3]
```

```
t_batch = t_train[:3]
```

```
grad_numerical = network.numerical_gradient(x_batch, t_batch)
```

```
grad_backprop = network.gradient(x_batch, t_batch)
```

```
# 각 가중치의 절대 오차의 평균을 구한다.
```

```
for key in grad_numerical.keys():
```

```
    diff = np.average( np.abs(grad_backprop[key] - grad_numerical[key]) )
```

```
    print(key + ":" + str(diff))
```

02. 오차역전파 검증

- 기존 학습 코드의 기울기 계산 부분을 오차역전파법으로 변경

02. 오차역전파 검증

```
(x_train, t_train), (x_test, t_test) = load_mnist(normalize=True, one_hot_label=True)
```

```
network = TwoLayerNet(input_size=784, hidden_size=50, output_size=10)
```

```
iters_num = 10000
```

```
train_size = x_train.shape[0]
```

```
batch_size = 100
```

```
learning_rate = 0.1
```

```
train_loss_list = []
```

```
train_acc_list = []
```

```
test_acc_list = []
```

```
iter_per_epoch = max(train_size / batch_size, 1)
```

02. 오차역전파 검증

```
for i in range(iters_num):
    batch_mask = np.random.choice(train_size, batch_size)
    x_batch = x_train[batch_mask]
    t_batch = t_train[batch_mask]

    # 기울기 계산
    #grad = network.numerical_gradient(x_batch, t_batch) # 수치 미분 방식
    grad = network.gradient(x_batch, t_batch) # 오차역전파법 방식(훨씬 빠르다)

    # 갱신
    for key in ('W1', 'b1', 'W2', 'b2'):
        network.params[key] -= learning_rate * grad[key]

    loss = network.loss(x_batch, t_batch)
    train_loss_list.append(loss)

if i % iter_per_epoch == 0:
    train_acc = network.accuracy(x_train, t_train)
    test_acc = network.accuracy(x_test, t_test)
    train_acc_list.append(train_acc)
    test_acc_list.append(test_acc)
    print(train_acc, test_acc)
```

03

학습 관련 기술

03. 학습 관련 기술

- 신경망 학습의 목적 → 손실 함수 값을 최소화하는 매개변수를 탐색 → 최적화
- 전체의 데이터가 아닌 확률적으로 추출하여 학습하는 SGD(Stochastic Gradient Descent)

$$W \leftarrow W - \frac{\eta \partial L}{\partial W}$$

```
class SGD:
    def __init__(self, lr=0.01):
        self.lr = lr

    def update(self, params, grads):
        for key in params.keys():
            params[key] -= self.lr * grads[key]
```

03. 학습 관련 기술

- 신경망 학습의 목적 → 손실 함수 값을 최소화하는 매개변수를 탐색 → 최적화
- 전체의 데이터가 아닌 확률적으로 추출하여 학습하는 SGD(Stochastic Gradient Descent)

```
network = TwoLayerNet(input_size=784, hidden_size=50, output_size=10)
optimizer = SGD()
```

```
for l in range(10000):
```

```
    ...
```

```
    x_batch, t_batch = get_mini_batch(...)
```

```
    grads = network.gradient(x_batch, t_batch)
```

```
    params = network.params
```


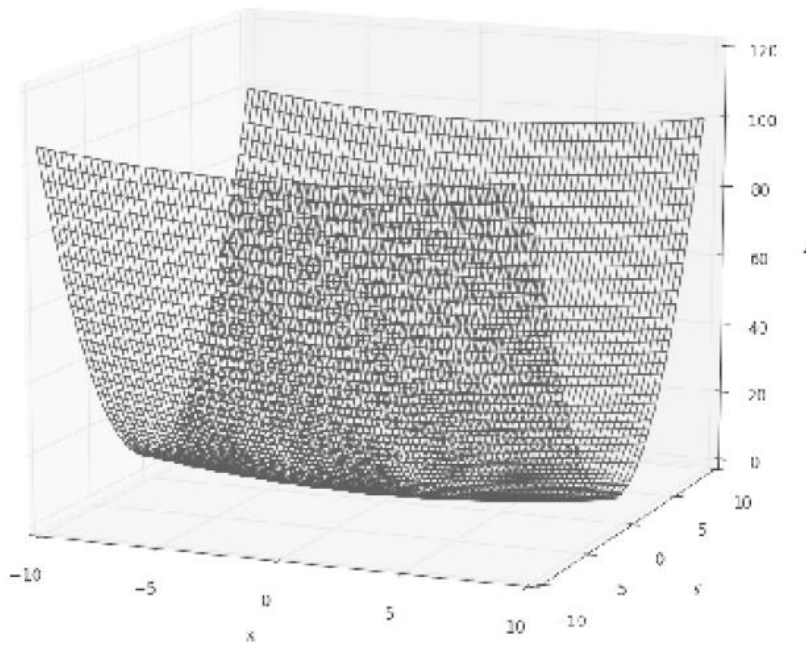
```
    optimizer.update(params, grads)
```

```
    ...
```

03. 학습 관련 기술

- SGD의 문제점


$$f(x, y) = \frac{1}{20}x^2 + y^2$$



03. 학습 관련 기술

- SGD의 문제점

$f(x, y) = \frac{1}{20}x^2 + y^2$ 에 대해 SGD 적용



03. 학습 관련 기술

- Momentum
- 기존의 개념에 대해 속도 가속도와 같은 개념을 추가
- v 는 초기값이 0인 속도
- α 는 가속도와 같은 역할(보통 0.9 등 1 이하의 값을 선택)

$$\begin{aligned}v &\leftarrow \alpha v - \frac{\eta \partial L}{\partial W} \\W &\leftarrow W + v\end{aligned}$$

$$\begin{aligned}\frac{\partial L}{\partial W_1} &= 5, \frac{\partial L}{\partial W_2} = 3 \\W &\leftarrow W - \eta \frac{\partial L}{\partial W_1} = W - 0.5 \\W &\leftarrow W - \eta \frac{\partial L}{\partial W_2} = W - 0.3\end{aligned}$$

기존 방법

$$\begin{aligned}v_1 &\leftarrow -\frac{\eta \partial L}{\partial W_1} = -0.5 \\W &\leftarrow W + v_1 = W - 0.5 \\v_2 &\leftarrow \alpha v_1 - \eta \frac{\partial L}{\partial W_2} = -0.45 - 0.3 = -0.75 \\W &\leftarrow W + v_2 = W - 0.75\end{aligned}$$


Momentum



03. 학습 관련 기술

- Momentum 적용

$$f(x, y) = \frac{1}{20}x^2 + y^2$$



- Momentum 구현

```
class Momentum:
    def __init__(self, lr=0.01, momentum=0.9):
        self.lr = lr
        self.momentum = momentum
        self.v = None

    def update(self, params, grads):
        if self.v is None:
            self.v = {}
            for key, val in params.items():
                self.v[key] = np.zeros_like(val)
        for key in params.keys():
            self.v[key] = self.momentum*self.v[key] - self.lr*grads[key]
            params[key] += self.v[key]
```

03. 학습 관련 기술


- AdaGrad
- 개별 매개변수에 적응적(Adaptive)으로 학습률을 조정하면서 학습을 진행

$$\begin{aligned} \mathbf{h} &\leftarrow \mathbf{h} + \frac{\partial L}{\partial \mathbf{W}} * \frac{\partial L}{\partial \mathbf{W}} \\ \mathbf{W} &\leftarrow \mathbf{W} - \eta \frac{1}{\sqrt{\mathbf{h}}} \frac{\partial L}{\partial \mathbf{W}} \end{aligned}$$

03. 학습 관련 기술

- AdaGrad 적용

$$f(x, y) = \frac{1}{20}x^2 + y^2$$




- AdaGrad 구현

```
class AdaGrad:
    def __init__(self, lr=0.01):
        self.lr = lr
        self.h = None

    def update(self, params, grads):
        if self.h is None:
            self.h = {}
            for key, val in params.items():
                self.h[key] = np.zeros_like(val)
        for key in params.keys():
            self.h[key] += grads[key] * grads[key]
            params[key] -= self.lr * grads[key] / (np.sqrt(self.h[key]) + 1e-7)
```

03. 학습 관련 기술

- Adam
- 위의 두 기법을 융합한 방법



- AdaGrad 구현

```
class Adam:
    def __init__(self, lr=0.001, beta1=0.9, beta2=0.999):
        self.lr = lr
        self.beta1 = beta1
        self.beta2 = beta2
        self.iter = 0
        self.m = None
        self.v = None
```

- AdaGrad 구현

```
def update(self, params, grads):
    if self.m is None:
        self.m, self.v = {}, {}
        for key, val in params.items():
            self.m[key] = np.zeros_like(val)
            self.v[key] = np.zeros_like(val)

    self.iter += 1
    lr_t = self.lr * np.sqrt(1.0 - self.beta2**self.iter) / (1.0 - self.beta1**self.iter)

    for key in params.keys():
        self.m[key] += (1 - self.beta1) * (grads[key] - self.m[key])
        self.v[key] += (1 - self.beta2) * (grads[key]**2 - self.v[key])

    params[key] -= lr_t * self.m[key] / (np.sqrt(self.v[key]) + 1e-7)
```


03. 학습 관련 기술

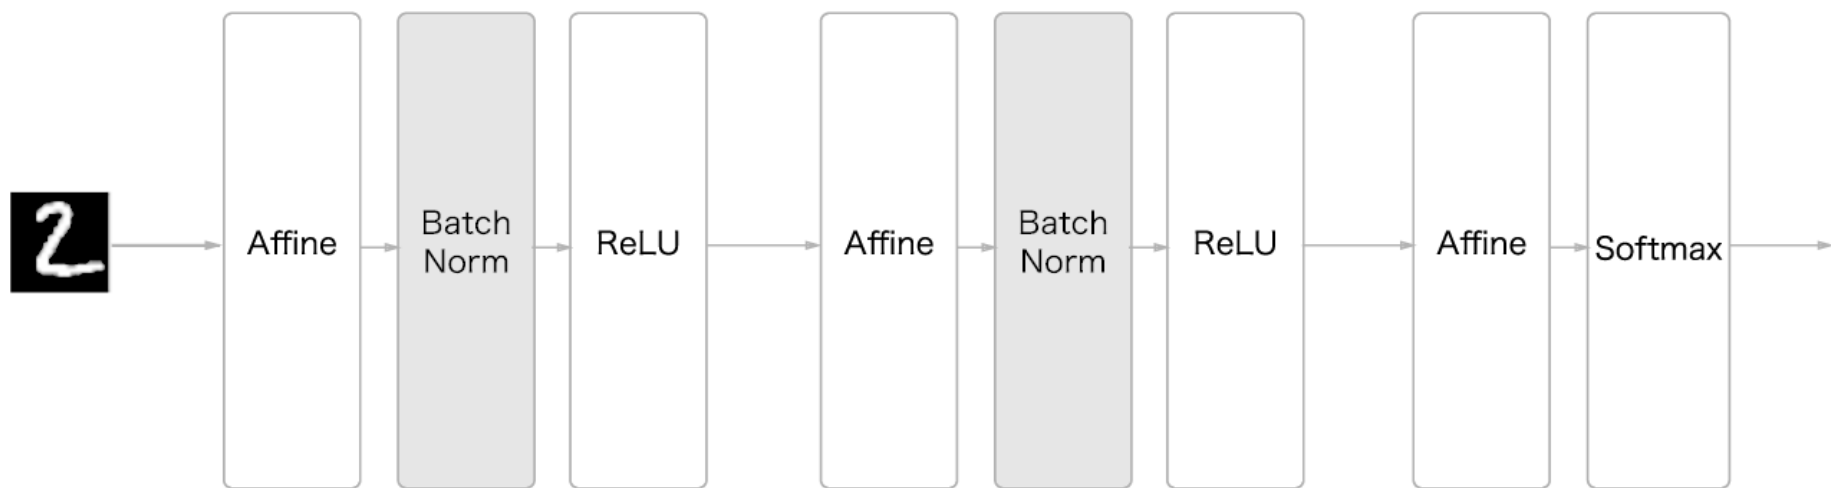
- 배치 정규화
- 학습 속도를 개선할 수 있고, 초기값에 크게 의존하지 않으며, 오버피팅을 억제
- 미니 배치를 평균이 0, 분산이 1이 되도록 정규화를 진행

$$\mu_B \leftarrow \frac{1}{m} \sum_{i=1}^m x_i \quad \sigma_B^2 \leftarrow \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$$

$$\hat{x}_i \leftarrow \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$


03. 학습 관련 기술

- 배치 정규화
- 학습 속도를 개선할 수 있고, 초기값에 크게 의존하지 않으며, 오버피팅을 억제
- 미니 배치를 평균이 0, 분산이 1이 되도록 정규화를 진행




03. 학습 관련 기술

- 배치 정규화에 따른 학습 속도




03. 학습 관련 기술

- 드롭 아웃
- 뉴런을 임의로 삭제하면서, 오버피팅을 억제하는 방식



(a) 일반 신경망




(b) 드롭아웃을 적용한 신경망

```
class Dropout:
    def __init__(self, dropout_ratio=0.5):
        self.dropout_ratio = dropout_ratio
        self.mask = None


    def forward(self, x, train_flg=True):
        if train_flg:
            self.mask = np.random.rand(*x.shape) > self.dropout_ratio
            return x * self.mask
        else:
            return x * (1.0 - self.dropout_ratio)

    def backward(self, dout):
        return dout * self.mask
```

03. 학습 관련 기술



일반



드롭 아웃 적용

